

# تحلیل هوشمند تصاویر پزشکی

## تمرین پنجم، بخش تئوری

جواد راضی (۴۰۱۲۰۴۳۵۴)

### سوال اول: Object Detection

منابع استفاده شده در پاسخ به سوال:

[Object detection: the reference architectures in medical imaging \(imaios.com\)](http://imaios.com)

[\[1803.08707\] Optimizing the Trade-off between Single-Stage and Two-Stage Object Detectors using Image Difficulty Prediction \(arxiv.org\)](https://arxiv.org/abs/1803.08707)

#### (الف) آشکارسازهای تک مرحله‌ای

- این مدل‌ها، تشخیص شی را به عنوان یک مسئله پیش‌بینی ساده می‌دانند که احتمالات کلاس‌ها و مختصات Bounding Box را مستقیماً از تصویر ورودی پیش‌بینی می‌کنند.
- برای کاربردهای بلادرنگ (Real-Time) مناسب‌تر است زیرا نیازی به مرحله ارسال Region Proposal که در شبکه‌هایی نظیر Fast-RCNN استفاده می‌شود ندارد.
- مثال‌هایی از این نوع آشکارساز:
  - YOLO (You Only Look Once)
  - SSD (Single Shot Multibox Detector)
- کاربرد: در تصویربرداری پزشکی، از آنها برای تشخیص بلادرنگ مشکلاتی مانند تشخیص ندول ریه و پولیپ استفاده می‌شود.

#### (ب) آشکارسازهای دو مرحله‌ای

- این آشکارسازها در مرحله اول، Region Proposals یا پیشنهادهای ناحیه‌ای (مکان‌های بالقوه حضور شیء) را تولید می‌کنند و سپس در مرحله دوم، این مناطق را طبقه‌بندی می‌کنند.

- از آنجا که این آشکارسازها فرآیندی دو مرحله‌ای دارند، از نظر زمانی کندتر هستند اما دقت بالاتری ارائه می‌دهند.
- مثال‌هایی از این نوع آشکارساز: R-CNN, Fast R-CNN, Faster R-CNN و Mask R-CNN
- کاربرد: در موقعیت‌هایی که دقت بسیار حائز اهمیت است، مانند تشخیص اجسام کوچک یا روی هم رفته مانند ضایعات یا گره‌ها، مورد استفاده قرار می‌گیرند. در تصویربرداری پزشکی، برای کارهایی نظیر تقسیم‌بندی معنایی و مکان‌یابی دقیق، مانند تشخیص تومورها و تقسیم‌بندی ساختارهای آناتومیک، به کار می‌روند.

## سوال دوم: تفسیرپذیری مدل

### منابع استفاده‌شده در پاسخ به سوال:

[\[1902.04893\] Why are Saliency Maps Noisy? Cause of and Solution to Noisy Saliency Maps \(arxiv.org\)](#)

### (الف) علل وجود نویز در Attribution Map ها، و راه‌حل‌های آن

1. **مسئله اشباع گرادیان‌ها (Gradient Saturation):** شبکه‌های عصبی عمیق اغلب از توابع فعال‌سازی مانند ReLU استفاده می‌کنند که می‌توانند به حالت اشباع برسند. وقتی یک تابع فعال‌سازی اشباع شود، تغییرات جزئی در ورودی تأثیر چندانی بر خروجی نخواهد داشت، که این امر به محو شدن گرادیان‌ها منجر می‌شود. این مسئله می‌تواند باعث ایجاد نقشه‌های حساسیت (saliency maps) پرسروصدا شود، چرا که گرادیان‌ها قادر به این نیستند که میان ویژگی‌ها ورودی، از لحاظ امنیت تمایز ایجاد کنند.

**راه‌حل:** تکنیک‌هایی مانند Integrated Gradients می‌توانند با یکپارچه‌سازی گرادیان در مسیر بین ورودی پایه تا ورودی واقعی، این مشکل را تا حدی رفع کنند و تصویری جامع‌تر از اهمیت ویژگی‌ها ارائه دهند که کمتر تحت تأثیر اشباع قرار می‌گیرد.

2. **عدم قطعیت مدل:** زمانی که یک مدل در پیش‌بینی‌های خود اطمینان ندارد، احتمالاً به دلیل ناکافی بودن داده‌های یادگیری، یا پیچیدگی ذاتی موجود در داده‌ها، گرادیان‌ها ممکن است ناپایدار باشند که نتیجه آن، نقشه‌های حساسیت پر از نویز خواهند بود.

**راه حل:** به کارگیری شبکه‌های عصبی بیزی (Bayesian Neural Networks) یا روش‌های انسمبل می‌تواند به سنجش و کاهش این عدم قطعیت کمک کند. این رویکردها توزیع احتمالی مدل‌ها یا پیش‌بینی‌های ممکن را در نظر می‌گیرند که می‌تواند به Attribution Map های ثابت‌تر و یکنواخت‌تری منجر شود.

**3 ویژگی‌های نامرتب در فعال‌سازی‌های ReLU:** توابع فعال‌سازی ReLU بدون ایجاد تمایز، هر ورودی بیشتر از صفر را عبور می‌دهند، که این می‌تواند به طور تصادفی ویژگی‌های نامرتب را در کنار ویژگی‌های مرتبط و Informative، مورد تأکید قرار دهد. این رفتار غیرانتخابی می‌تواند جزئیات غیرضروری را در نقشه‌های حساسیت وارد کند و الگوهای پراهمیت را مخدوش سازد.

**راه حل:** رویکرد گرادین تصحیح‌شده، این مشکل را با پیاده‌سازی آستانه‌های لایه به لایه در طول فرآیند Back-Propagation حل می‌کند. این متد به طور انتخابی فعال‌سازی‌هایی که به شکل قابل‌توجهی در فرآیند تصمیم‌گیری مدل مشارکت ندارند را حذف می‌کند. بدین ترتیب، شفافیت، تفسیر پذیری و ارزش نقشه‌های حساسیت تولیدشده افزایش می‌یابد.

## (ب) نحوه ارزیابی Selectivity

### بخش اول:

الگوریتم Pixel-Flipping با انجام مراحل زیر، حساسیت روش‌های انتساب را ارزیابی می‌کند:

1. **حذف تکراری ویژگی‌های مهم:** شروع با حذف ویژگی‌های برجسته‌ترین (پیکسل‌ها) که توسط بردار اهمیت R شناسایی شده‌اند، هر پیکسل را از تصویر حذف می‌کند.

2. **سنجش عملکرد مدل:** پس از حذف هر پیکسل، عملکرد مدل دوباره ارزیابی می‌شود تا امتیاز پیش‌بینی جدیدی به دست آید.

3. **پیگیری کاهش عملکرد:** تغییرات در امتیازات پیش‌بینی ثبت شده و یک منحنی p\_curve ایجاد می‌کند که نشان می‌دهد با حذف ویژگی‌های مهم‌تر، عملکرد مدل چگونه کاهش می‌یابد.

4. **ارزیابی Fidelity:** شدت شیب کاهش در منحنی  $p\_curve$ ، میزان Fidelity (وفاداری) روش تفسیر مدل را نشان می‌دهد. کاهش سریع، دلالت بر اهمیت واقعی ویژگی‌های شناسایی‌شده برای تصمیم‌گیری مدل دارد و صحت و دقت روش را تأیید می‌کند.

### بخش دوم:

محور افقی نمودارها، درصد پیکسل‌های دستکاری‌شده (Pertubated) در تصویر ورودی را نشان می‌دهد که نمایانگر میزان تغییرات اعمال‌شده توسط الگوریتم Pixel-Flipping می‌باشد. در این محور، 0% به معنای عدم دستکاری پیکسل‌هاست و 100% به این معنی است که تمام پیکسل‌هایی که توسط روش‌های تفسیر و توضیح، به عنوان مرتبط‌ترین شناخته شده‌اند، تغییر یافته‌اند.

محور عمودی، امتیاز میانگین خروجی مدل‌های شبکه عصبی مربوطه (VGG-16 و ResNet-50) را همزمان با افزایش Pertubation اندازه‌گیری می‌کند. این امتیاز، اطمینان یا احتمالی را که مدل به تصمیم یا دسته‌بندی اولیه اختصاص داده است، کمی می‌کند، به طوری که امتیازات بالاتر، نشان‌دهنده اطمینان بیشتر هستند. با حذف پیکسل‌های بیشتر، این امتیاز کاهش می‌یابد.

## سوال سوم: Federated Learning

### منابع استفاده‌شده در پاسخ به سوال:

[Decentralized Distributed Multi-institutional PET Image Segmentation Using a Federated Deep Learning Framework - PubMed \(nih.gov\)](#)

[Personalized Federated Learning with Theoretical Guarantees: A Model-Agnostic Meta-Learning Approach \(neurips.cc\)](#)

(الف)

**یادگیری فدرالی،** یک رویکرد در یادگیری ماشین است که در آن، مدل‌ها بر روی دستگاه‌های لبه یا سرورهای متعدد و غیرمتمرکز که نمونه‌های داده‌های محلی را در خود نگهداری می‌کنند، بدون تبادل این داده‌ها، آموزش داده می‌شوند. این رویکرد امکان بهره‌برداری از تمام منابع محاسباتی موجود را فراهم می‌کند و تمرین مدل‌ها را بر روی مجموعه‌ای بزرگ‌تر از نقاط داده‌ای ممکن می‌سازد، ضمن حفظ حریم خصوصی داده‌ها.

یادگیری فدرالی از یادگیری توزیع شده و یادگیری غیرمتمرکز در چند جنبه متفاوت است. در یادگیری توزیع شده، اغلب فرض می شود که داده ها، میان گره ها، به صورت مستقل و یکسان توزیع شده اند (i.i.d) و فرآیند یادگیری توسط یک سرور مرکزی مدیریت و کنترل می شود. در سوی دیگر، یادگیری فدرالی فرض i.i.d را ندارد و برای مقابله با داده های غیر i.i.d. در سراسر گره ها طراحی شده است. این مورد در بسیاری از کاربردها، سناریویی واقع بینانه تر را ارائه می دهد.

یادگیری غیرمتمرکز به یادگیری فدرالی نزدیک تر است، چرا که در این نوع یادگیری نیز آموزش مدل ها بر روی نمونه داده های محلی صورت می گیرد. با این حال، در یادگیری غیرمتمرکز، هیچ سرور مرکزی ای برای هماهنگی فرآیند یادگیری وجود ندارد. در عوض، گره ها به صورت مستقیم با یکدیگر ارتباط برقرار می کنند تا مدل های خود را به روزرسانی کنند.

(ب)

هدف الگوریتمی که در مقاله ارائه شده است، یافتن یک مدل مشترک اولیه است که کلاینت های فعلی یا جدید بتوانند به آسانی با انجام یک یا چند مرحله از کاهش گرادیان با توجه به داده های محلی خود، آن را به داده های محلی شان تطبیق دهند.

الگوریتم ارائه شده، مدل مشترک را با در نظر گرفتن مشتق مرتبه دوم (Hessian) در قانون به روزرسانی، برای کلاینت های فردی شخصی سازی می کند. ماتریس Hessian که مشتق های جزئی مرتبه دوم یک تابع را نمایندگی می کند، اطلاعاتی درباره انحنای تابع فراهم می آورد. در زمینه این الگوریتم، Hessian برای تنظیم پویای نرخ یادگیری بر اساس انحنای تابع Loss استفاده می شود، که می تواند به یادگیری کارآمدتر منجر شود.

در الگوریتم Per-FedAvg، هر کلاینت با استفاده از داده های محلی خود یک گرادیان تصادفی محاسبه می کند و مدل محلی خود را با استفاده از هر دو گرادیان و یک عبارت شامل Hessian به روز می کند. اصطلاح Hessian از ماتریس Identity کم می شود و با نرخ یادگیری ضرب می گردد، و سپس این نتیجه در گرادیان ضرب می شود. این عملیات به طور مؤثر نرخ یادگیری را بر اساس انحنای تابع Loss در نقطه فعلی فضای پارامتر تنظیم می کند.

پس از آنکه هر کلاینت مدل محلی خود را به روز کرده است، آن را به سرور باز می گرداند، که سپس مدل جهانی را با میانگین گیری از مدل های دریافتی به روز می کند. این فرایند برای تعداد مشخصی از

ایتریشن‌ها تکرار می‌شود. استفاده از Hessian به این شیوه به الگوریتم اجازه می‌دهد تا مدل مشترک را به ویژگی‌های خاص داده‌های محلی هر کلاینت تطبیق دهد، که منجر به مدلی بیشتر شخصی‌سازی شده می‌شود.